



جامعة محمد الخامس بالرباط  
Université Mohammed V de Rabat

# MÉMOIRE DE PROJET DE DATAWAREHOUSE

## Création et Mise en œuvre d'un Datawarehouse pour l'Analyse des données de vente sur Internet

Réalisé par :

**Derrouich Jaouhar**

Génie logiciel (GL1)

Encadré par

**Mme. El Asri Bouchra**

## Table des matières

<b>INTRODUCTION .....</b>	<b>4</b>
<b>1. Tâche 1 : Création du datawarehouse : .....</b>	<b>5</b>
1.1. Création de LightAdventureWorksDW : .....	5
1.2. Création des dimensions : .....	5
<b>2. Tâche 2 : Load LightAdventureWorksDW .....</b>	<b>8</b>
2.1. Chargement de dimension Customers : .....	8
2.2. Chargement de dimension Products : .....	10
2.3. Chargement de dimension Dates : .....	11
2.4. Chargement de dimension InternetSales : .....	11
2.5. Exécution et début de chargement des données dans l'entrepôt: .....	13
<b>3. Tâche 3 : Création du cube .....</b>	<b>13</b>
3.1. Dimension Dates.....	13
3.2. Dimension Customers.....	14
3.3. Dimension Products.....	14
3.4. Data source view .....	15
<b>4. Tâche 4 : Exploration des données avec SSRS, EXCEL et le web.....</b>	<b>16</b>
4.1. SSRS .....	16
4.2. EXCEL .....	18
<b>Conclusion : .....</b>	<b>20</b>

## Table des figures

Figure 1 Schéma en étoile .....	7
Figure 2 Slowly Changing Dimension Customer .....	8
Figure 3 Slowly Changing Dimention Columns for Customers .....	9
Figure 4 Slowly Changing Dimension Products .....	10
Figure 5 Slowly Changing Dimention Columns for Products .....	10
Figure 6 Load Dates .....	11
Figure 7 Slowly Changing Dimension InternetSales .....	11
Figure 8 Slowly Changing Dimention Columns for InternetSales .....	12
Figure 9 Loading data .....	13
Figure 10 Dates attributes Relationships .....	13
Figure 11 Customers attributes Relationships .....	14
Figure 12 Products attributes Relationships .....	14
Figure 13 Data source view .....	15
Figure 14 Internet Sales Count per Country .....	16
Figure 15 Sales Count for each country in a year per product .....	17
Figure 16 Sales count per Year .....	17
Figure 17 Sales count per Country .....	18
Figure 18 Graph of internet Sales Count per country .....	18
Figure 19 graph of internet Sales count per year .....	19
Figure 20 Graph of sales count per country .....	19
Figure 21 Graph of sales count for each country in year per product .....	20

## INTRODUCTION

L'informatique décisionnelle est l'informatique à l'usage des décideurs et des dirigeants d'entreprises. Elle désigne les moyens, les outils et les méthodes qui permettent de collecter, consolider, modéliser et restituer les données, matérielles ou immatérielles, d'une entreprise en vue d'offrir une aide à la décision et de permettre à un décideur d'avoir une vue d'ensemble de l'activité traitée.

Les données opérationnelles sont extraites périodiquement de sources hétérogènes : fichiers plats, fichiers Excel, base de données (DB2, Oracle, SQL Server, etc.), service web, données massives et stockées dans un entrepôt de données. Cet entrepôt porte le nom de datawarehouse. Un datawarehouse représente une base de données : les données étant intégrées, non volatiles, et historisées. Grâce à la plateforme SQL Server Integration Services (SSIS), cet entrepôt central sera rempli. Mais avant, il est indispensable de définir sa structure. Avant de remplir le datawarehouse dans SSIS, la conception de celui-ci s'impose. Viennent donc les notions de table de faits et table de dimension.

Pour notre cas ici on va créer un datawarehouse pour l'analyse des données de vente sur Internet en passant par plusieurs tâches.

## 1. Tâche 1 : Création du datawarehouse :

### 1.1. Création de LightAdventureWorksDW :

Dans cette étape il s'agit de mettre en place un entrepôt de données LightAdventureWorksDW. Et cela implique la création du schéma ainsi que les dimensions et les tables de faits.

Pour la créer il faut d'abord Lancer SSMS et se connecter à votre instance de SQL Server. Ouvrir une nouvelle fenêtre de requête en cliquant sur le bouton Nouvelle requête. Puis d'après le contexte de la base de données master, on va créer une nouvelle base de données appelée LightAdventureWorksDW utilisons script suivante :

```
CREATE DATABASE [LIGHTADVENTUREWORKSDW]
CONTAINMENT = NONE
ON PRIMARY
( NAME = N'LIGHTADVENTUREWORKSDW', FILENAME = N'C:\Program Files\Microsoft SQL
Server\MSSQL15.MSSQLSERVER\MSSQL\DATA\LIGHTADVENTUREWORKSDW.mdf' ,
  SIZE = 307200KB , MAXSIZE = UNLIMITED, FILEGROWTH = 10240KB
)
LOG ON
( NAME = N'LIGHTADVENTUREWORKSDW_log', FILENAME = N'C:\Program Files\Microsoft SQL
Server\MSSQL15.MSSQLSERVER\MSSQL\DATA\LIGHTADVENTUREWORKSDW_log.ldf' ,
  SIZE = 3094592KB , MAXSIZE = 2048GB , FILEGROWTH = 10%)
WITH CATALOG_COLLATION = DATABASE_DEFAULT
GO
IF OBJECT_ID('dbo.SeqCustomerDwKey','SO') IS NOT NULL
DROP SEQUENCE dbo.SeqCustomerDwKey;
GO
CREATE SEQUENCE dbo.SeqCustomerDwKey AS INT
START WITH 1
INCREMENT BY 1;
GO
```

### 1.2. Création des dimensions :

Pour créer les dimensions on a exécuté les requêtes suivant :

- La dimension Customers :

```
USE LIGHTADVENTUREWORKSDW;
GO
CREATE TABLE dbo.Customers
(
  CustomerDwKey INT NOT NULL,
  CustomerKey INT NOT NULL,
  FullName NVARCHAR(150) NULL,
  EmailAddress NVARCHAR(50) NULL,
  BirthDate DATE NULL,
  MaritalStatus NCHAR(1) NULL,
  Gender NCHAR(1) NULL,
  Education NVARCHAR(40) NULL,
  Occupation NVARCHAR(100) NULL,
  City NVARCHAR(30) NULL,
  StateProvince NVARCHAR(50) NULL,
```

```

CountryRegion NVARCHAR(50) NULL,
Age AS
CASE
WHEN DATEDIFF(yy, BirthDate, CURRENT_TIMESTAMP) <= 40
THEN 'Younger'
WHEN DATEDIFF(yy, BirthDate, CURRENT_TIMESTAMP) > 50
THEN 'Older'
ELSE 'Middle Age'
END,
CurrentFlag BIT NOT NULL DEFAULT 1,
CONSTRAINT PK_Customers PRIMARY KEY (CustomerDwKey)
);
GO

```

- La dimension Products :

```

USE LIGHTADVENTUREWORKSDW;
GO
CREATE TABLE dbo.Products
(
ProductKey INT NOT NULL,
ProductName NVARCHAR(50) NULL,
Color NVARCHAR(15) NULL,
Size NVARCHAR(50) NULL,
SubcategoryName NVARCHAR(50) NULL,
CategoryName NVARCHAR(50) NULL,
CONSTRAINT PK_Products PRIMARY KEY (ProductKey)
);
GO

```

- La dimension Dates

```

CREATE TABLE dbo.Dates
(
DateKey INT NOT NULL identity(1,1),
FullDate DATE NOT NULL,
MonthNumberName NVARCHAR(15) NULL,
CalendarQuarter TINYINT NULL,
CalendarYear SMALLINT NULL,
CONSTRAINT PK_Dates PRIMARY KEY (DateKey)
);
GO

```

- La dimension InternetSales

```

USE LIGHTADVENTUREWORKSDW;
GO
CREATE TABLE dbo.InternetSales
(
InternetSalesKey INT NOT NULL IDENTITY(1,1),
CustomerDwKey INT NOT NULL,
ProductKey INT NOT NULL,
DateKey INT NOT NULL,
OrderQuantity SMALLINT NOT NULL DEFAULT 0,
SalesAmount MONEY NOT NULL DEFAULT 0,
UnitPrice MONEY NOT NULL DEFAULT 0,
DiscountAmount FLOAT NOT NULL DEFAULT 0,
CONSTRAINT PK_InternetSales
PRIMARY KEY (InternetSalesKey)
);

```

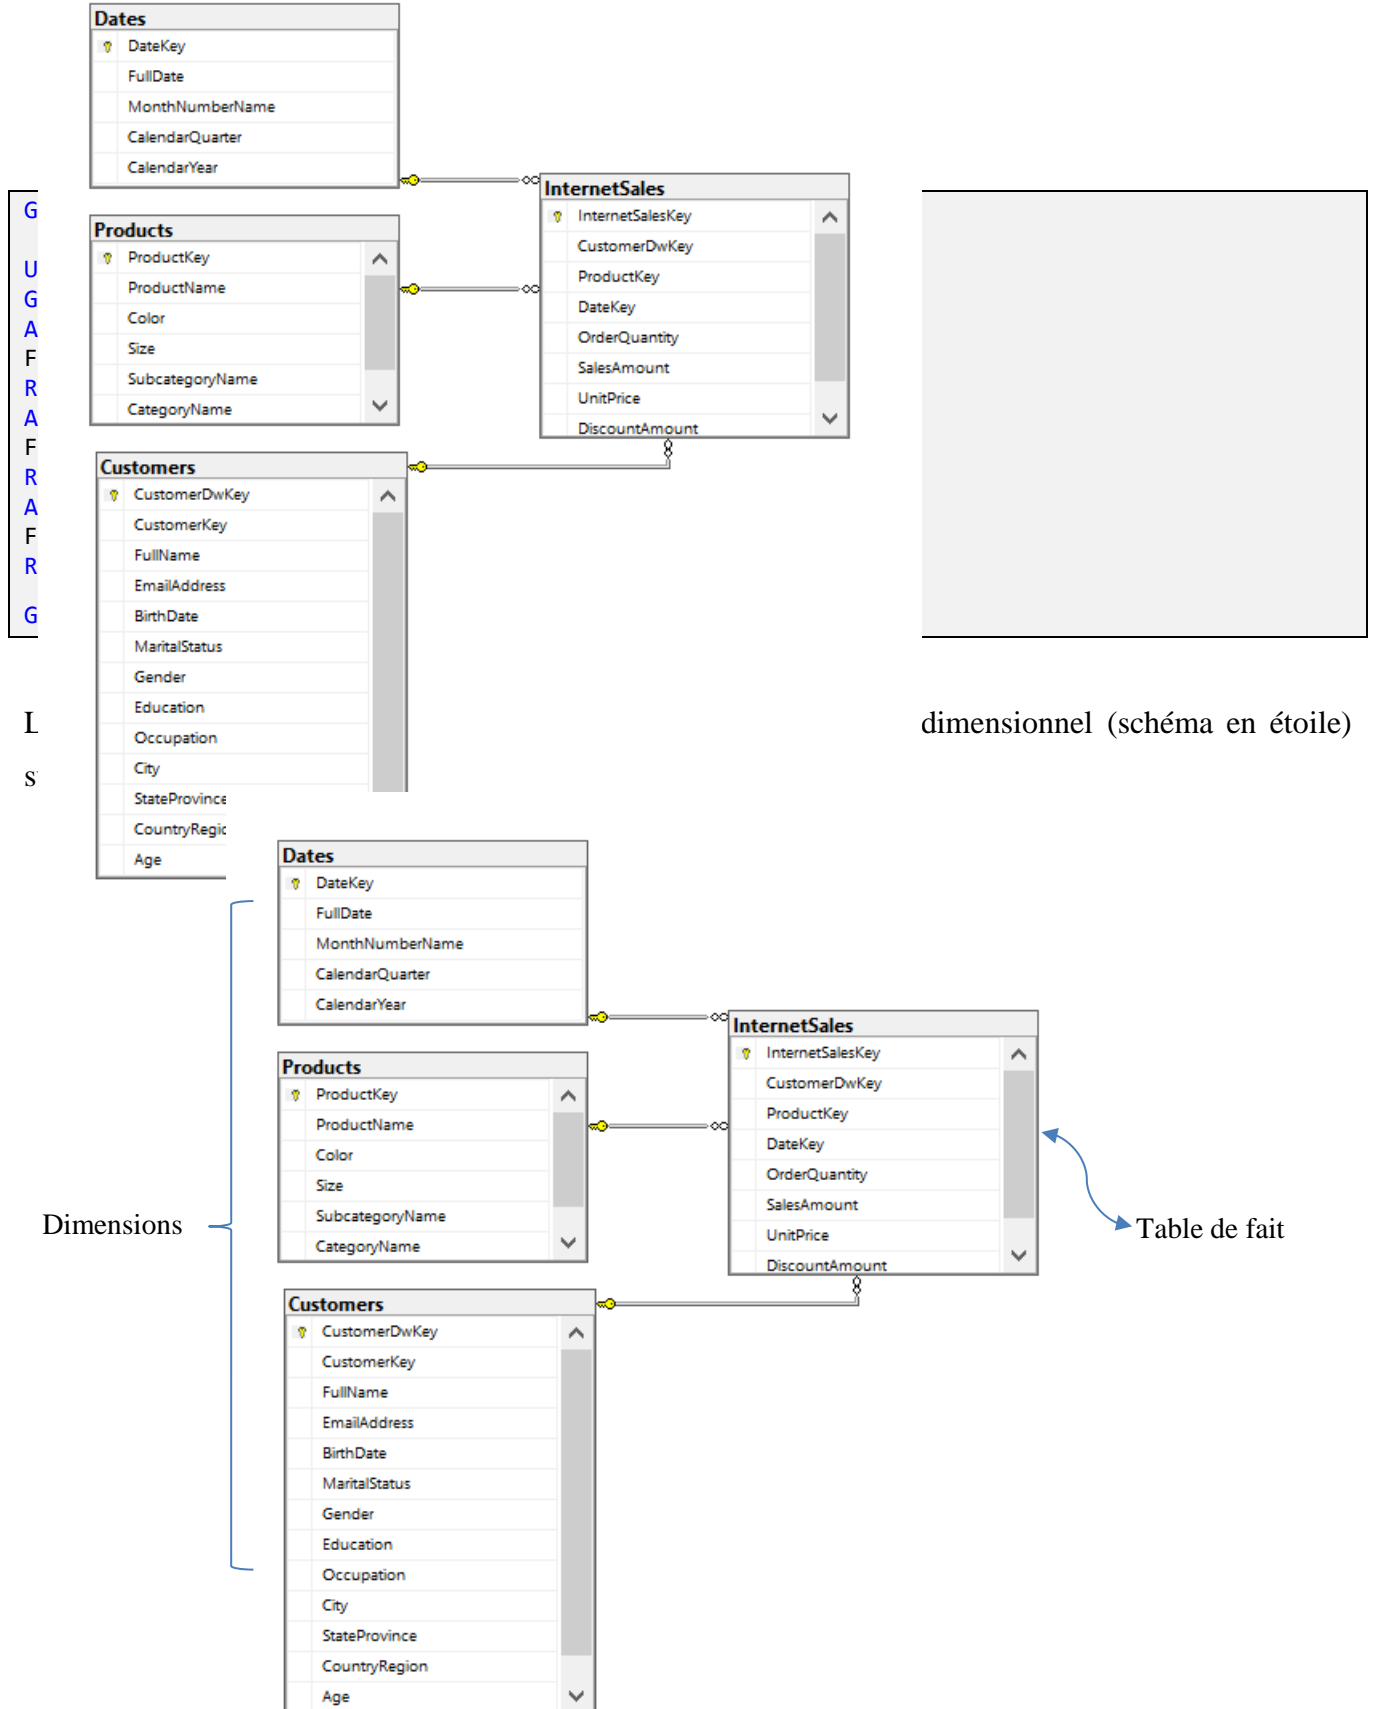


Figure 1 Schéma en étoile

En effet, la table de faits contient les données (faits) qui représentent la valeur des mesures sur lesquelles va porter l'analyse, quant aux dimensions, elles présentent les axes avec lesquels on veut faire l'analyse. On trouve une dimension client, une dimension produit, et date.

## 2. Tâche 2 : Load LightAdventureWorksDW

Dans cette tâche il s'agit d'alimenter le datawarehouse LightAdventureWorksDW depuis AdventureWorks2012. Pour cela on va utiliser le Slowly Changing Dimensions car on alimente depuis une base de données transactionnelle.

### 2.1. Chargement de dimension Customers :

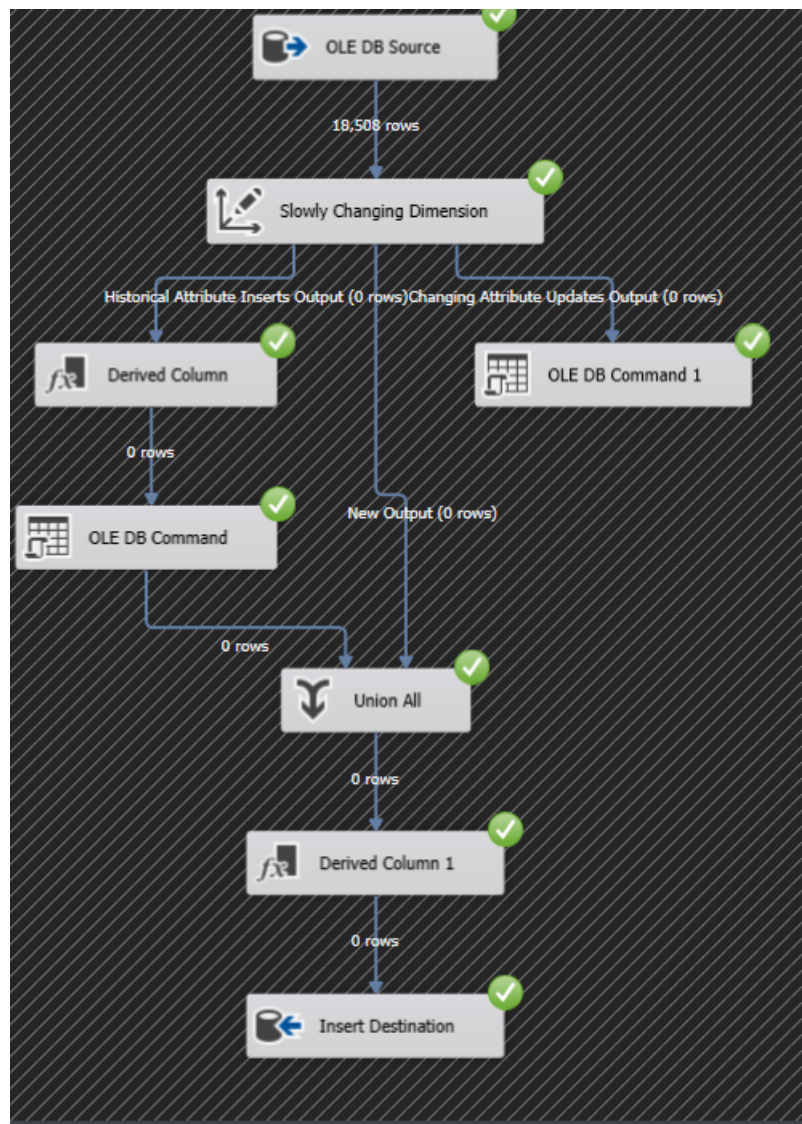


Figure 2 Slowly Changing Dimension Customer



On a utilisé dans la source OLE DB pour récupérer les données de AdventureWorks2012 la requête SQL suivante :

```
SELECT NEXT VALUE FOR LIGHTADVENTUREWORKSDW.dbo.SeqCustomerDwKey AS CustomerDwKey, C.CustomerID
AS CustomerKey ,
    CONCAT(P.FirstName,P.MiddleName,P.LastName) AS FullName ,
    E.EmailAddress AS EmailAddress ,
    ADDR.City AS City,
    SP.Name AS StateProvince,
    CR.Name AS CountryRegion

FROM AdventureWorks2012.Sales.Customer C,
    AdventureWorks2012.Person.Person P,
    AdventureWorks2012.Person.EmailAddress E ,
    AdventureWorks2012.Person.BusinessEntityAddress A ,
    AdventureWorks2012.Person.Address ADDR,
    AdventureWorks2012.Person.StateProvince SP,
    AdventureWorks2012.Person.CountryRegion CR

WHERE C.PersonID = P.BusinessEntityID
AND P.BusinessEntityID = E.BusinessEntityID
AND P.BusinessEntityID = A.BusinessEntityID
AND A.AddressID = ADDR.AddressID
AND ADDR.StateProvinceID = SP.StateProvinceID
AND SP.CountryRegionCode = CR.CountryRegionCode
```

Et pour les attributs, j'ai choisi comme *Historical attribute* les colonnes City, CountryRegion, EmailAddress et StateProvince puisque pour avoir une trace de la version précédente du client lorsque l'une de ces colonnes a changé (on rappelle que l'objectif est d'analyser les ventes donc on a besoin de savoir par exemple les lieux des clients).

**Slowly Changing Dimension Columns**  
Manage the changes to column data in your slowly changing dimensions by setting the change type

**Fixed Attribute**  
Select this type when the value in a column should not change. Changes are treated as errors.

**Changing Attribute**  
Select this type when changed values should overwrite existing values. This is a Type 1 change.

**Historical Attribute**  
Select this type when changes in column values are saved in new records. Previous values are saved in records marked as outdated. This is a Type 2 change.

Select a change type for slowly changing dimension columns:

Dimension Columns	Change Type
City	Historical attribute
CountryRegion	Historical attribute
CustomerDwKey	Fixed attribute
EmailAddress	Historical attribute
FullName	Changing attribute
StateProvince	Historical attribute

Remove

Help < Back Next > Finish >> Cancel

Figure 3 Slowly Changing Dimension Columns for Customers

## 2.2. Chargement de dimension Products :

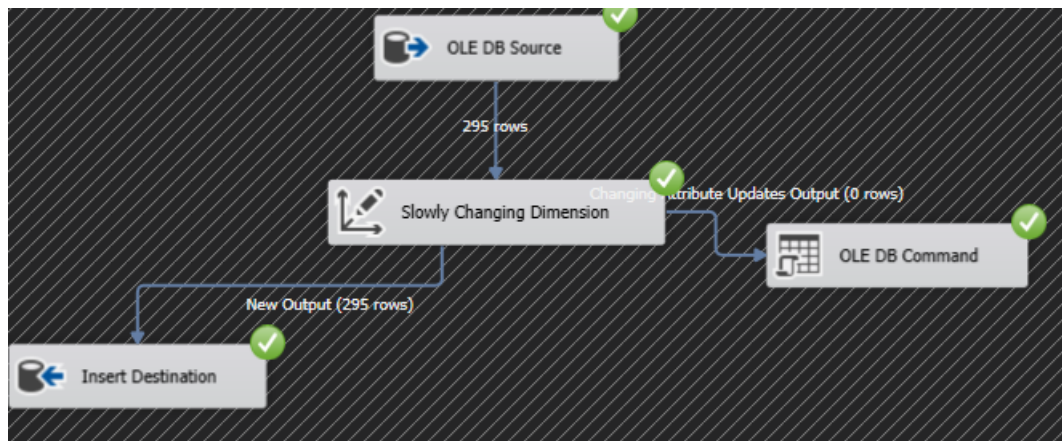


Figure 4 Slowly Changing Dimension Products

On a utilisé dans la source OLE DB pour récupérer les données de AdventureWorks2012 la requête SQL suivante :

```
SELECT p.ProductID as ProductKey, p.Name as ProductName, p.Color as Color, p.Size as Size,
s.Name as SubcategoryName, c.Name as CategoryName
FROM AdventureWorks2012.Production.Product p, AdventureWorks2012.Production.ProductCategory c,
AdventureWorks2012.Production.ProductSubcategory s
WHERE p.ProductSubcategoryID = s.ProductSubcategoryID and s.ProductCategoryID =
c.ProductCategoryID;
```

Et pour les attributs, j'ai choisi tous les colonnes comme *Changing attribute* puisque pour moi une fois l'une de ces colonnes a changé ça sert à rien d'historiser la version précédente.

**Fixed Attribute**  
Select this type when the value in a column should not change. Changes are treated as errors.

**Changing Attribute**  
Select this type when changed values should overwrite existing values. This is a Type 1 change.

**Historical Attribute**  
Select this type when changes in column values are saved in new records. Previous values are saved in records marked as outdated. This is a Type 2 change.

Select a change type for slowly changing dimension columns:

Dimension Columns	Change Type
CategoryName	Changing attribute
Color	Changing attribute
ProductName	Changing attribute
Size	Changing attribute

Figure 5 Slowly Changing Dimention Columns for Products

### 2.3. Chargement de dimension Dates :

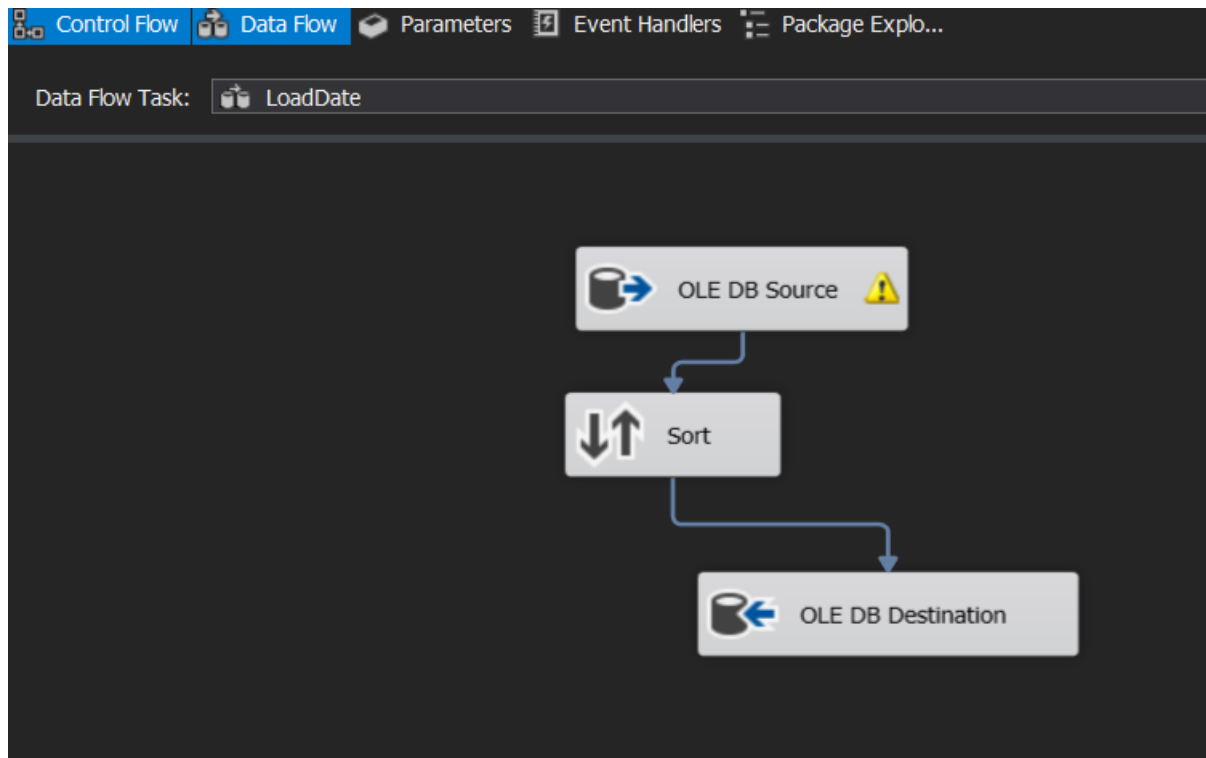


Figure 6 Load Dates

On a utilisé dans la source OLE DB pour récupérer les données de AdventureWorks2012 la requête SQL suivante :

```
SELECT SalesOrderID as DateKey , CONVERT(date, OrderDate) as FullDate,  
SUBSTRING(CONVERT(CHAR(8), OrderDate, 112), 5, 2)  
+ ' ' + DATENAME(month, OrderDate) as MonthNumberName,  
DATEPART(QUARTER, OrderDate ) as CalendarQuarter, YEAR(OrderDate) as CalendarYear  
FROM AdventureWorks2012.Sales.SalesOrderHeader
```

### 2.4. Chargement de dimension InternetSales :

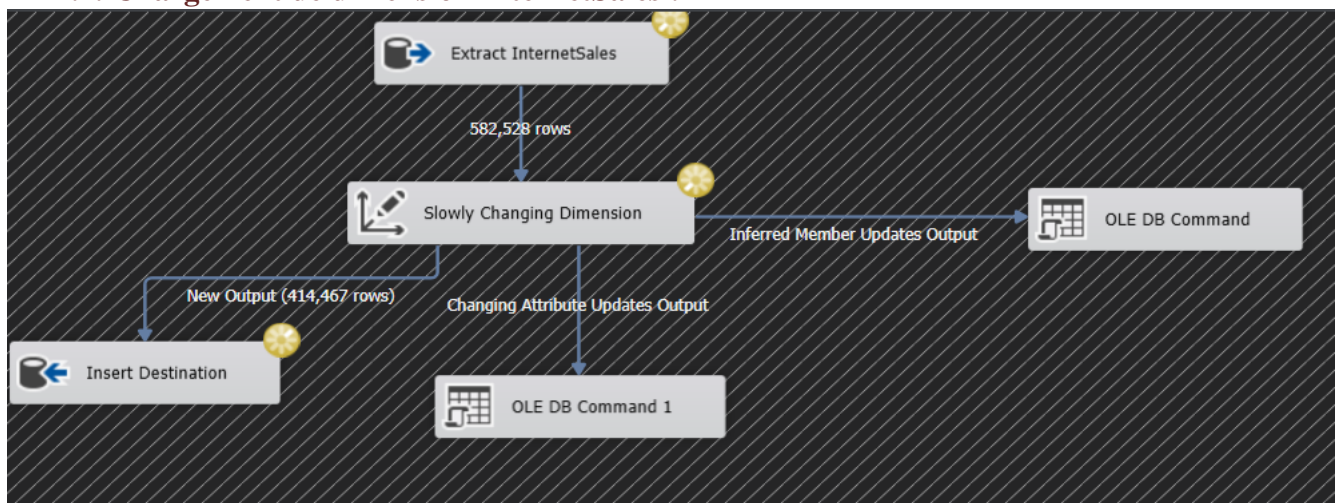



Figure 7 Slowly Changing Dimension InternetSales

On a utilisé dans la source OLE DB pour récupérer les données de AdventureWorks2012 la requête SQL suivante :

```
SELECT
C.CustomerDwKey as CustomerID,
SD.ProductID,
D.Datekey,
SD.OrderQty as OrderQuantity,
SD.OrderQty*SD.UnitPrice AS SalesAmount ,
SD.UnitPrice,
convert(Float,SD.UnitPriceDiscount*convert(Float,SD.OrderQty)) AS DiscountAmount
FROM
AdventureWorks2012.Sales.SalesOrderDetail AS SD,
AdventureWorks2012.Sales.SalesOrderHeader AS SH,
LIGHTADVENTUREWORKSDW.dbo.Customers AS C,
LIGHTADVENTUREWORKSDW.dbo.Products AS P,
LIGHTADVENTUREWORKSDW.dbo.Dates AS D
WHERE
SD.SalesOrderID = SH.SalesOrderID
AND C.CustomerKey = SH.CustomerID
AND P.ProductKey = SD.ProductID
AND D.Fulldate = SH.OrderDate;
```

Et pour les attributs, j'ai choisi comme *Changing attribute* toutes les colonnes sauf les foreign keys.

 Slowly Changing Dimension Wizard

### Slowly Changing Dimension Columns

Manage the changes to column data in your slowly changing dimensions by setting the

**Fixed Attribute**  
Select this type when the value in a column should not change. Changes are treated as errors.

**Changing Attribute**  
Select this type when changed values should overwrite existing values. This is a Type 1 change.

**Historical Attribute**  
Select this type when changes in column values are saved in new records. Previous values are saved in records marked as outdated. This is a Type 2 change.

Select a change type for slowly changing dim

Dimension Columns	Change Type
DateKey	Fixed attrib...
DiscountAmount	Changing a...
OrderQuantity	Changing a...
ProductKey	Fixed attrib...
SalesAmount	Changing a...
UnitPrice	Changing a...

Figure 8 Slowly Changing Dimention Columns for InternetSales

## 2.5. Exécution et début de chargement des données dans l'entrepôt:

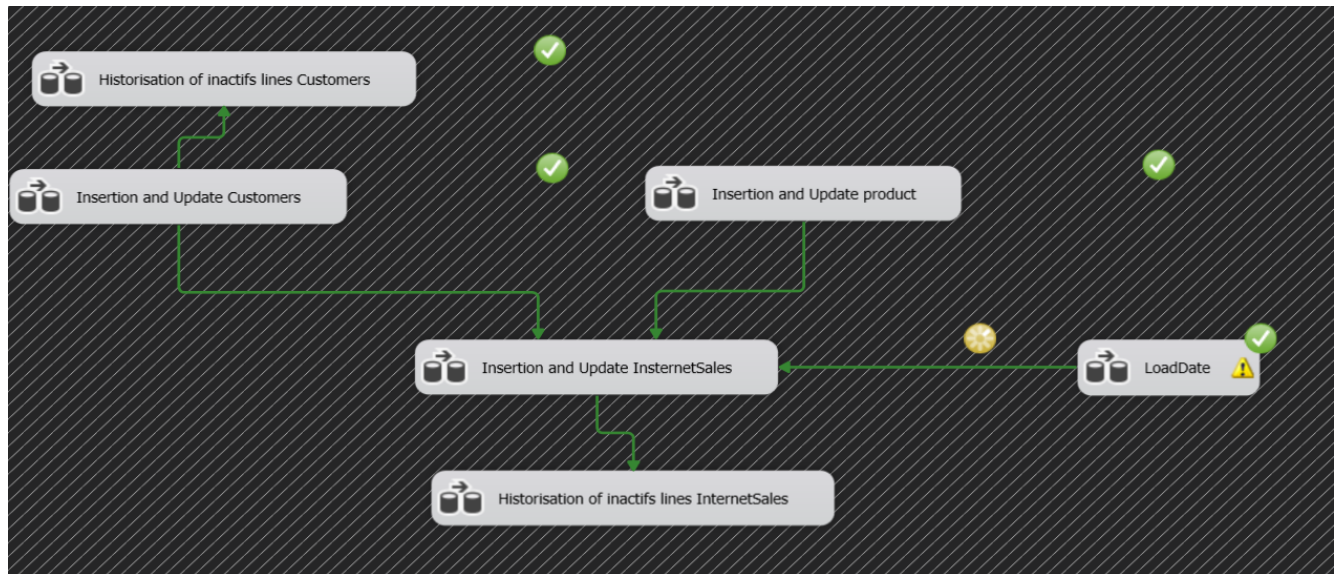


Figure 9 Loading data

Il est évident qu'on a des Historisation puisqu'on a des attributs historisés.

## 3. Tâche 3 : Création du cube

A l'aide de SSAS, on va créer le cube OLAP correspondant au sujet Vente. En optimisant la construction du cube.

### 3.1. Dimension Dates

On a créé la hiérarchie suivante :

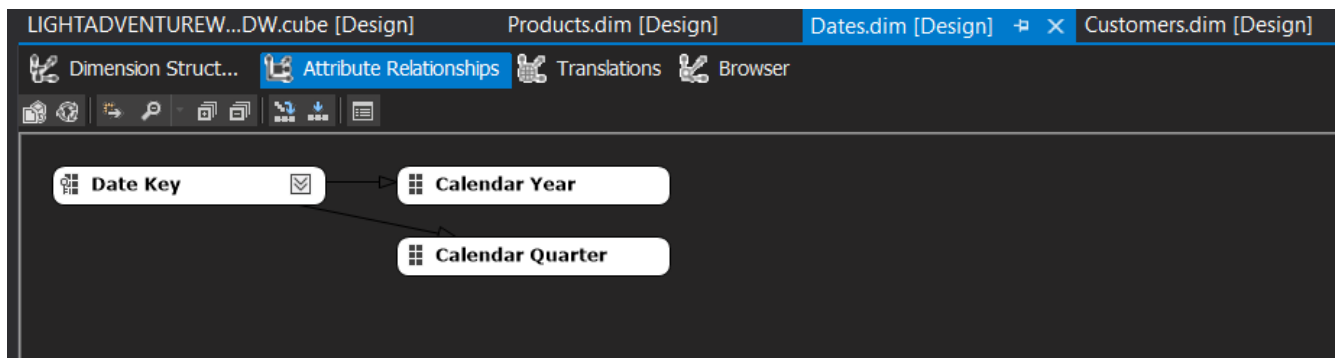


Figure 10 Dates attributes Relationships

### 3.2. Dimension Customers

On a créé la hiérarchie suivante :

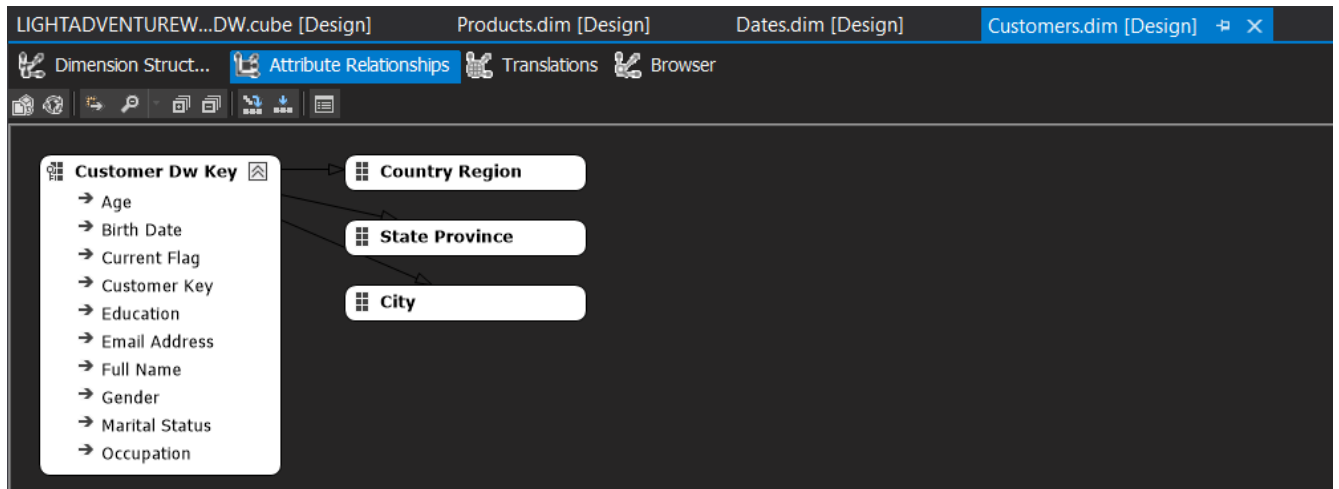


Figure 11 Customers attributes Relationships

### 3.3. Dimension Products

On a créé la hiérarchie suivante :

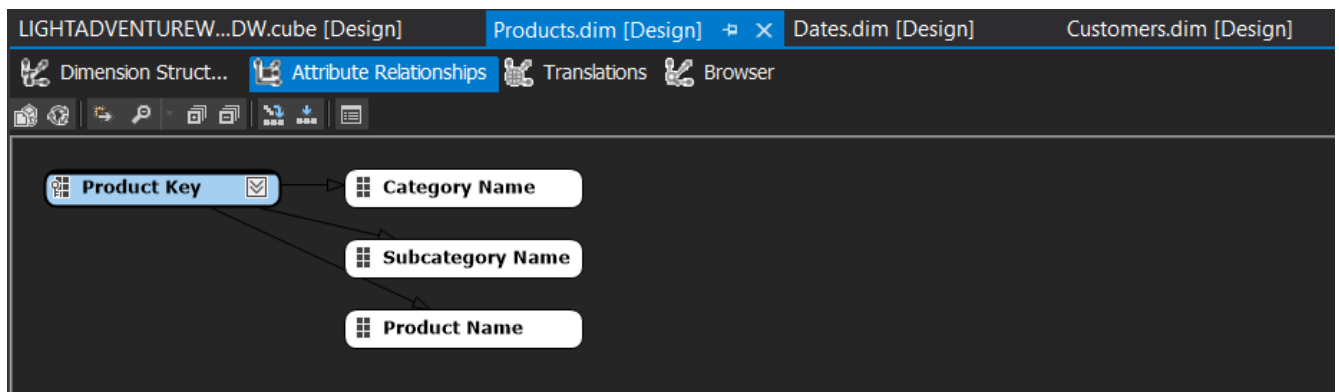


Figure 12 Products attributes Relationships

### 3.4. Data source view

Donc on obtient le résultat suivant :

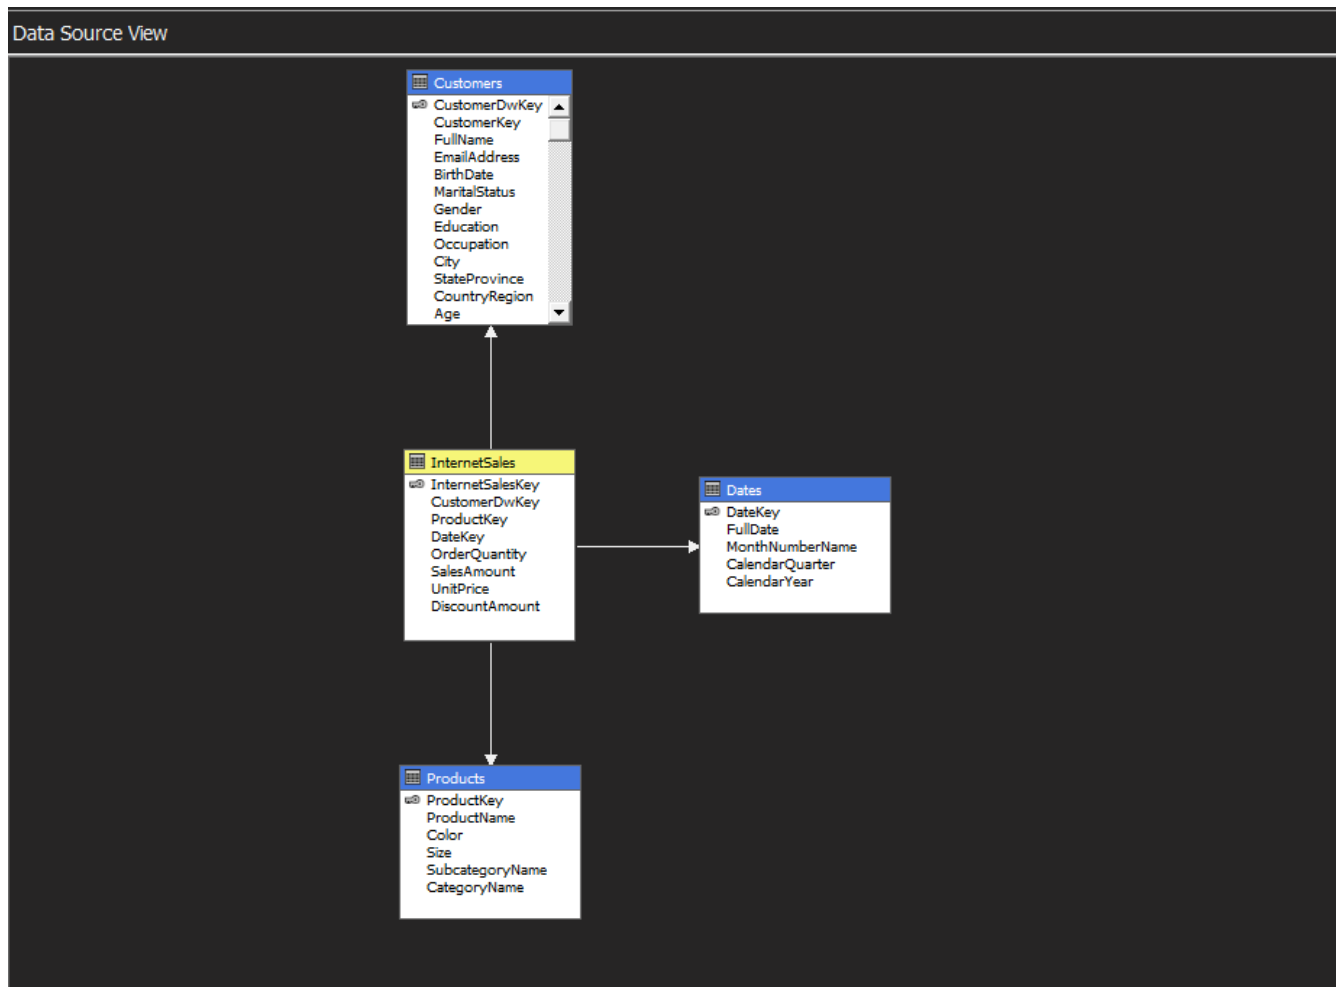


Figure 13 Data source view

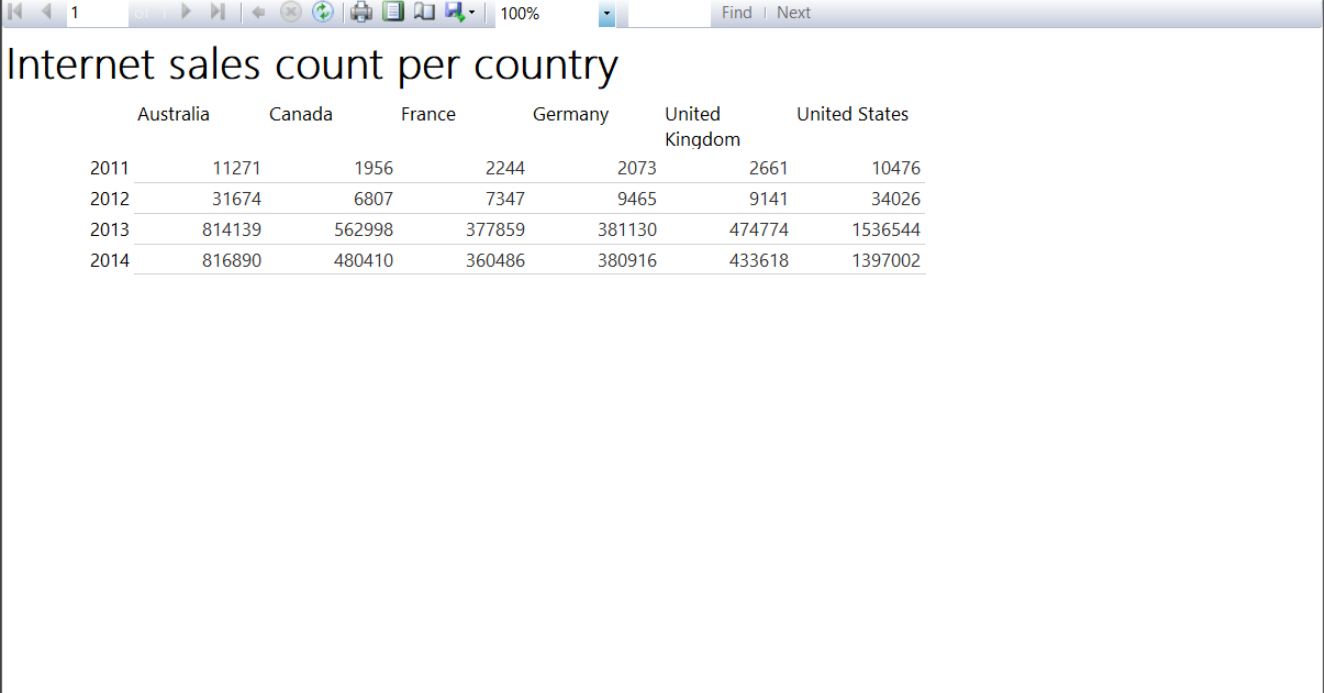
## 4. Tâche 4 : Exploration des données avec SSRS, EXCEL et le web

Dans cette étape, on va créer des rapports types matriciels avec SSRS bien documentés, des graphes avec Excel et une sélection de données à mettre sur le web.

### 4.1. SSRS

Sous la SSRS on a générer les matrices suivant :

Nombre des achats par internet par pays dans chaque année.



	Australia	Canada	France	Germany	United Kingdom	United States
2011	11271	1956	2244	2073	2661	10476
2012	31674	6807	7347	9465	9141	34026
2013	814139	562998	377859	381130	474774	1536544
2014	816890	480410	360486	380916	433618	1397002

*Figure 14 Internet Sales Count per Country*





Nombre des achats par pays :



## Sales count per Country

Country Region	Internet Sales Count
Australia	1673974
Canada	1052171
France	747936
Germany	773584
United Kingdom	920194
United States	2978048

Figure 17 Sales count per Country

### 4.2. EXCEL

Sous Excel on a générer les graphes suivant :

Nombre des achats par internet par pays :

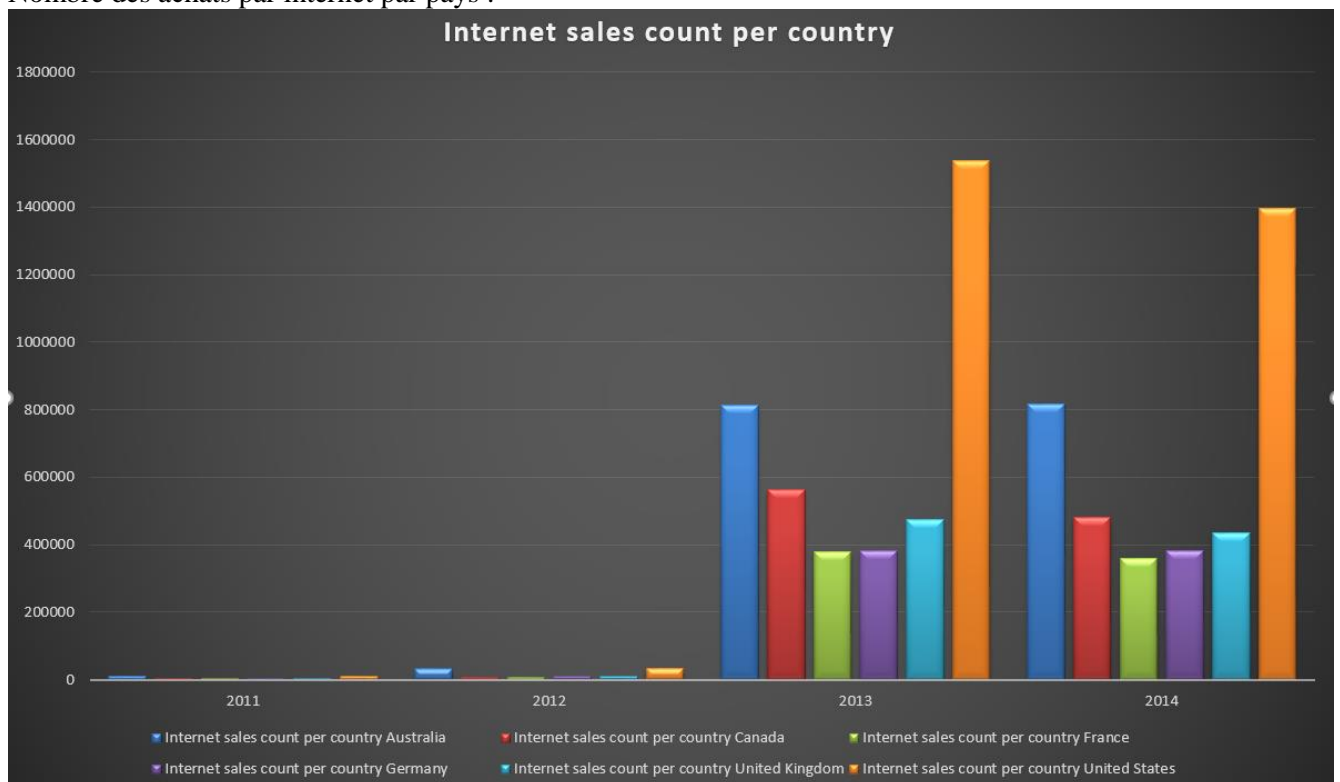


Figure 18 Graph of internet Sales Count per country

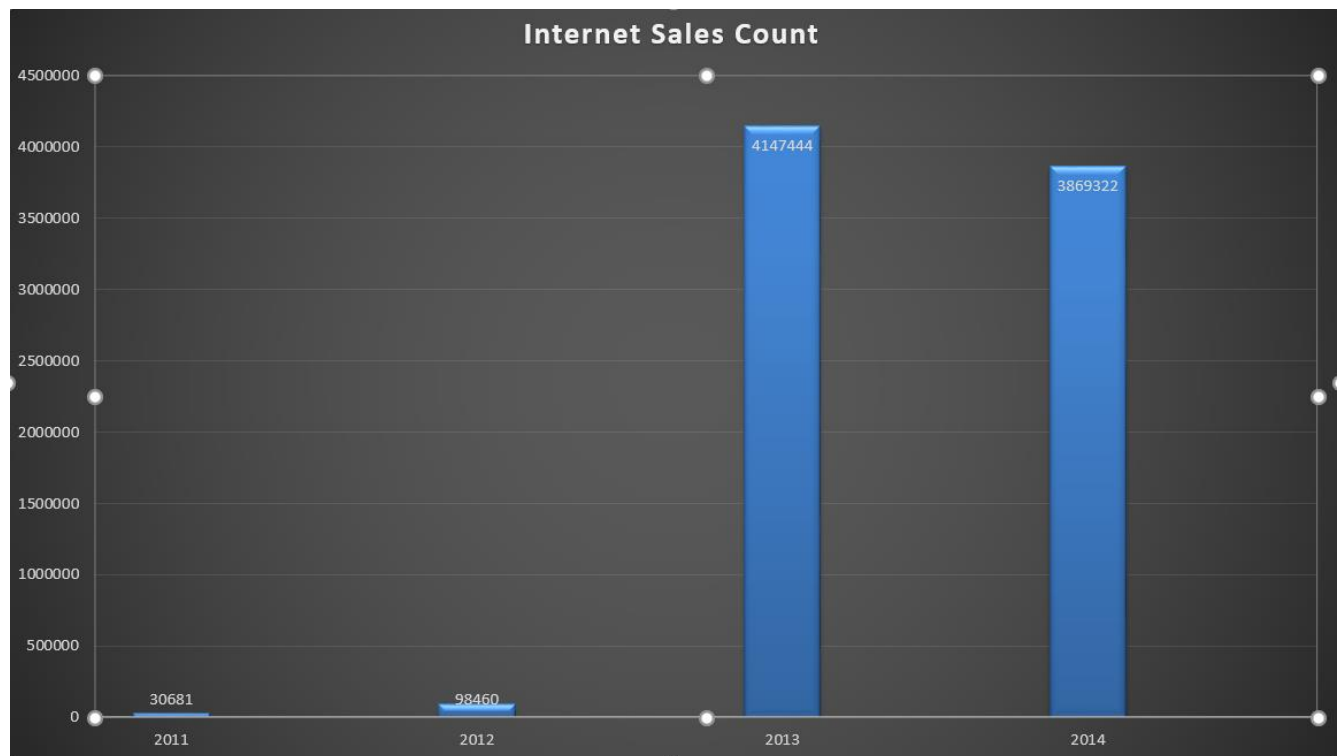


Figure 19 graph of internet Sales count per year





Figure 20 Graph of sales count per country



## Conclusion :

L'utilisation des Datawarehouse est très demandé aujourd'hui dans le monde de l'entreprise, demande qui répond au besoin toujours plus présent des utilisateurs d'avoir les bonnes informations au bon moment. Il entre dans le cadre de l'informatique décisionnelle ; son but est de fournir un ensemble de données servant de référence unique, utilisée pour la prise de décisions dans l'entreprise par le biais de statistiques et de rapports réalisés via des outils de Reporting. D'un point de vue technique, il sert surtout à 'délester' les bases de données opérationnelles des requêtes pouvant nuire à leurs performances.